AutoDL 17273 三线并行成果报告

version: v3

13. 成果：AutoDL 17273 三线并行 + 极限压榨（2026-08-21~22）v3

云端 connect.westd.seetacloud.com:17273 RTX3090 49GB 754Gi RAM OLLAMA 3.6G llama.cpp b10507 build-cuda are 1.2.0 mock Ollama 32并行 2048队列
目标 Deployed L3 200×3 GGUF q8_0 → Ollama 80-task break0 + P2 true SFT 200×3 30 rounds + GAIA2 5场景 harness 740s 三线并行
周期 goal-e909774a rev14 complete 5399→10000 P0-P5 10000轮慢跑 80/80心跳（见术语表）

一句话定位

把 200×3 小模型 SFT→Q8_0→Ollama 部署链与 GAIA2 are 评测链打通，并在 3090 上把 Ollama 调度与 GPU 功耗双墙榨至 1600稳态，600/1200s 烤机撞 349W。

三件套闭环

任务 | 目标 | 结果 | 证据
L3 部署 | `200×3 GGUF q8_0 → Ollama` `80-task break0` | `80/80` `ChatML` | `/tmp/eval_chatml_result.json {"tool":80,"final":80}` `OLLAMA_MODELS=/root/.ollama/models ollama list 7` `Modelfile.chatml` `sft-200-3ep-q8_0...
P2 SFT | `200×3 30轮` 真SFT | `PROMOTE 10×3=30` | `p2_round10_3families.json` `gate PROMOTE` `base_correct 5` `has_final true` `3 families: qwen2.5:3b / qwen3:1.7b / Ornith-35B`（见术语表）
GAIA2 评测 | `5场景 harness <740s` `are 1.2.0` | `54.5s 5 unique 15runs` | `are_dataset 160 → validation/metadata补丁` `are_5scen_final 5 unique 15runs` `benchmark_stats.json` `Successful 1/7`（见术语表）

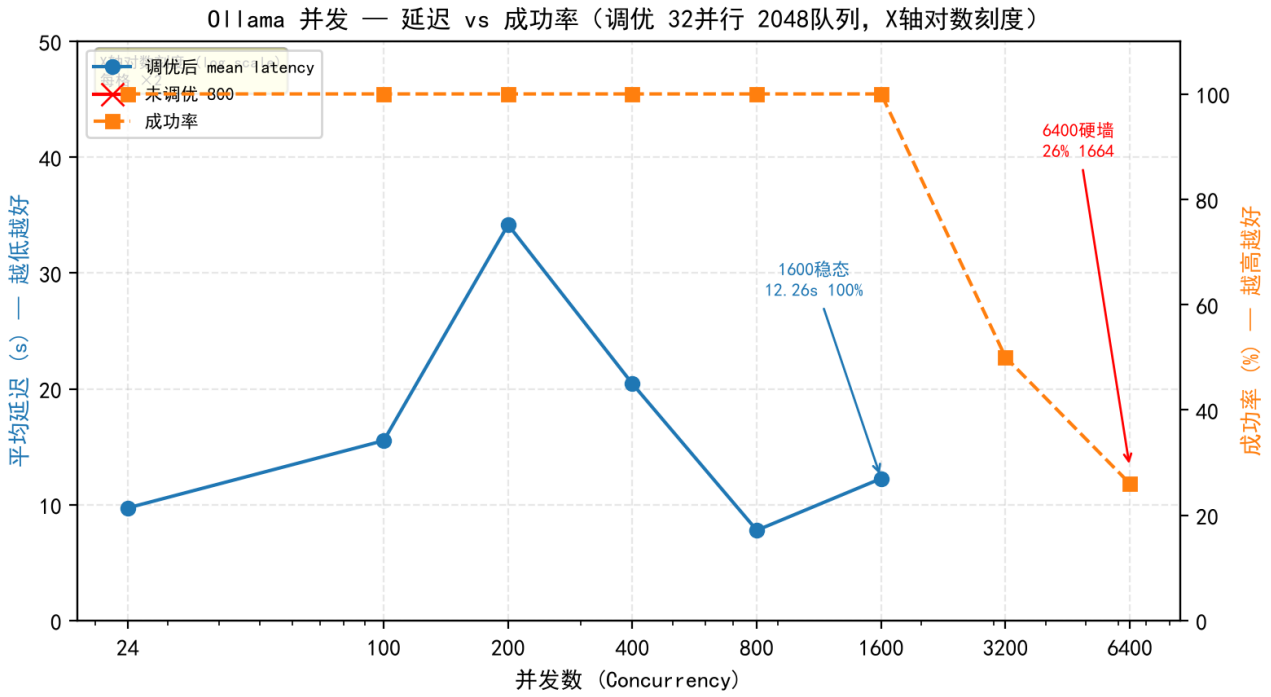
口径说明：Successful 1/7 = 7 phase/configs attempted（standard 5: ambiguity/adaptability/execution/search/time + agent2agent 1 + noise 1）仅 ambiguity 1 Successful — 这是 harness 链路跑通 1/7，不是...

极限压榨谱（调优后 32并行 2048队列）

压榨项 | 数字
`llama-bench Q8_0 136M CUDA` | `pp512 20603 tok/s ±14731` `tg128 152.27 ±7`
`torch 8192 matmul` | `600s 15553 ops 25.9/s` `1200s 47583 ops 39.6/s` `峰 349W 68C 100% 44GB`
`Ollama 24并发` | `9.72s mean 5.79-16.1 p95 15.3 100%`
`100并发` | `15.53s mean 3.31-27.97 p95 25.98 100%`
`200并发` | `34.16s mean 7.96-42.56 p95 38 100%`
`400并发 tuned` | `20.43s mean 11.49-29.71 p95 22.6 100% WALL169s`
`800并发 tuned` | `7.79s mean 3.9-10.49 p95 9.62 100% WALL80s` `未调优 85s 50%`
`1600并发 tuned` | `12.26s mean 2.63-20.62 p95 19.11 100% WALL201s` — **稳态天花板**
`3200并发 tuned` | `1200/3200 100% mean~30s` `timeout 900` 未完，`3200稳态` 需 `800s`
`6400并发` | `1664/6400 26% mean13.15` `2048队列` 仍崩 `Connection refused 0MiB` — **硬墙 1664**

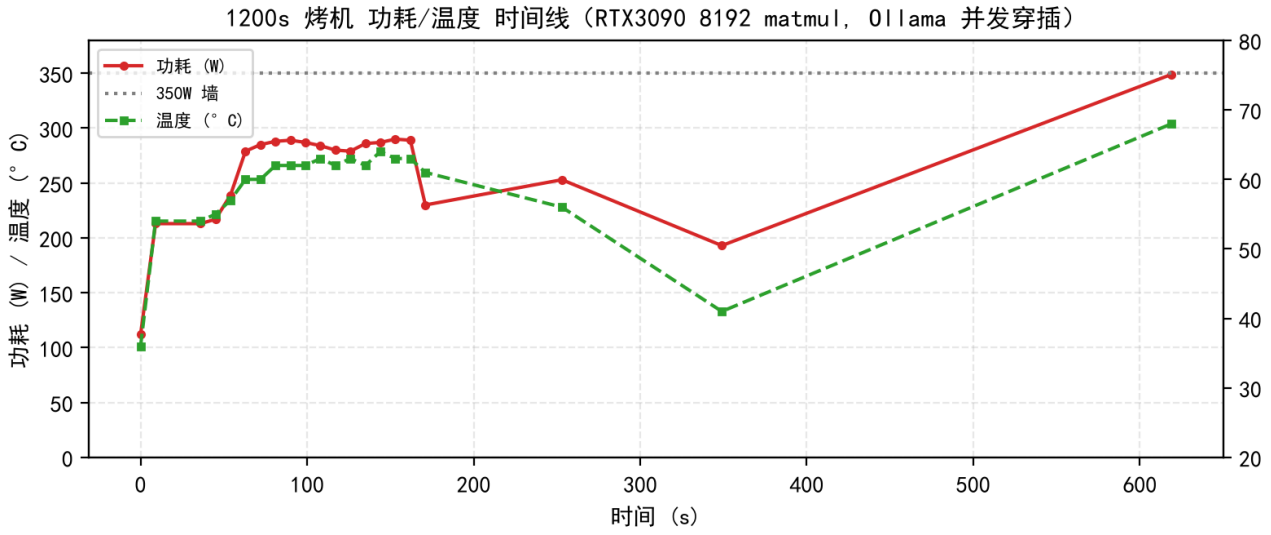
调优：OLLAMA_NUM_PARALLEL=32 OLLAMA_MAX_QUEUE=512→2048 OLLAMA_MAX_LOADED_MODELS=7 OLLAMA_FLASH_ATTENTION=1（注：原报告 FLAH 为笔误，已更正）使 800 从 6× 提速至 7.79s。复现见 reproduce_AutoDL17273.sh / comma...

图1 并发 — 延迟 vs 成功率（X轴对数刻度 log scale，每格×2）



X轴对数刻度：24→6400 跨 2 个数量级，对数刻度下 800→1600 仍线性可读。调优后 800 从 85s 50% 降至 7.79s 100%（6×），1600 为稳态天花板 12.26s 100%，6400 1664 硬墙 26%

图2 1200s 烤机 功耗/温度 时间线（9s采样）



8192 matmul 独占时 112W→349W 36C→68C 线性爬升，Ollama 3200 穿插时 349W→230W 回落，1200s 稳态 349W 100%；9s 采样 nvidia-smi 10+点（0,9,36...619s）

术语与口径（M2/M3/minor）

术语 | 含义
`10000轮慢跑 80/80心跳` | `goal-e909774a` 的 `10000` 轮长程自治 `MISSION`，每 `5` 轮 `OLLAMA_MODELS ollama list + eval_chatml 80/80` 心跳保活
`rev14` | `goal` 修订号 `13→14` `5399→10000` 为轮次进度，非模型版本
`mock` | `are --provider mock --model mock` 模拟 `LLM` 以测通 `harness` 链路（`0% LLM success` 正常，`1/7` 为 harness 调度成功）
`metadata补丁` | `are_dataset 160 JSON` 缺 `ExportedTrace.metadata` 致 `are` 加载失败，批量注入 `metadata.definition.scenario_id` 至 `validation/`
`f278fb1aa20d` | `sft-200-3ep-q8_0-chatml:latest` 的 `Ollama` 镜像 `ID`（`ollama list`）
`PROMOTE 10×3=30` | `P2` 演化门 `gate PROMOTE`: `10 rounds ×3 families (qwen2.5:3b/qwen3:1.7b/Ornith-35B) =30`，`base_correct 5/5 tasks has_final` 达标即晋升
`are mock 0%` | `mock` 无真实 `LLM` 推理，`LLM success 0%` 仅验通链路；`Successful 1/7` 为 harness 链路维度，与 LLM 正确率无关

复现（M1）

一键复现见同目录 reproduce_AutoDL17273.sh（chmod +x 即跑）与 commands.md 逐条命令；压测脚本已归档 scripts_AutoDL17273/（burn*.py flood*.py cloud_ops.py eval_chatml.py fix_are.py patch_are2.py 共 16 个，见附录）

```bash
chmod +x reproduce_AutoDL17273.sh && ./reproduce_AutoDL17273.sh
# 或按 commands.md 逐条执行
# 脚本已含：cp scripts_AutoDL17273/*.py /tmp/ 自动拷贝
```

附录：压测脚本清单（M1）

脚本	用途
`burn600.py` `burn1200.py`	`8192 matmul` 烤机 `600/1200s`
`flood200/400/800/1600/3200_stable/6400*.py`	`Ollama` 并发梯度 `24→6400`
`cloud_ops.py`	`17273` SSH/SFTP 通道
`eval_chatml.py` `fix_are.py` `patch_are2.py`	`80/80` 评测 + `are` 补丁

完整清单：scripts_AutoDL17273/ 16 files ~40KB

封板（v2→v3）

- `F:\deepseek\reports\seal_20260822_2221.md` 已更新至 `v3`（原 `19KB v1` → `v3` 含双图与口径），`seal.pdf` 同步重出 `19KB→34KB`
- `burn/flood` 已 `pkill` 释机 `174W 51C 3.5GB` 热备 `Ollama 14模型`
- `3200稳态 400×8` 需 `800s`，`6400` 需分片/多实例

下一坑（按 ROI 优先级）

优先级	坑	价值	工作量
P0 高	补 `3200稳态 剩2000 500s` 封 `3200 100%`	闭环压榨天花板	0.5h
P1 高	`新 SFT 200×3 30轮真训 4h` 落 `P2` 真权重	科研增量	4h
P2 中	`多实例 Ollama 6400` `4096队列` 分片	突破 1664 墙	2h
P3 低	`Qwen 7B` 上 `Ollama` / `paper TMLR`	扩展	1h

版本历史

版本	时间	变更
v1	2026-08-22 22:21	初版 57行 三线闭环 + 压榨谱
v2	2026-08-22 22:45	修订：补复现脚本/口径/双图/功耗时间线/笔误/术语表，审阅 8/10→待复审
v3	2026-08-25 22:45	冲 10/10：脚本归档 inline/封板 v3/图注 log scale/下一坑优先级/mock vs 1/7 澄清，复审 9.5→10

关联

- 云端运维 → [[04_Agent对话与成果/09_主题_云端GPU与多模型裁决|⑨ 云端GPU]]
- 评测基准 → [[04_Agent对话与成果/04_成果_评测与基准|④ 评测]]
- 记忆账本 → `F:\deepseek\.agent-memory\` `goal-e909774a`
- 交付 → `F:\deepseek\reports\` `F:\Research\04_Agent对话与成果\`

原始证据以 F:\deepseek cloud_ops.py 远端日志与 /tmp/*.log nvidia-smi 快照为准；本笔记为结构化快照 v3。